

FIAP PAULISTA

1CCPZ

GUSTAVO BITENCOURT-RM: 568885, DANIEL VIEIRA-RM: 573326, LEONARDO

TAKACHI-RM: 569066 E GIOVANE SALAZAR-RM: 570396

Sprint 3 – GoodWe Challenge

SÃO PAULO 2026

1CCPZ

Sprint 3 – GoodWe Challenge

Orientador: Prof Rodolfo Magliari

São Paulo

2026

Sumário

Introdução	4
Objetivo	4
Base de Dados	5
01) Probabilidade acima da Mediana	6
02) Probabilidade no intervalo Média $\pm 2s$	7
03) Modelagem com Regressão Linear	7
Conclusão	9
Referências	9

Introdução

Este relatório apresenta a análise estatística e a modelagem por Regressão Linear solicitadas no Challenge Sprint 3. A base de dados utilizada contém registros de sessões de recarga de veículos elétricos, e é a mesma utilizada na Sprint 1. A variável escolhida para a análise de Distribuição Normal foi a “Energy Consumed (kWh)”, enquanto a Regressão Linear utiliza a “Charging Duration (hours)” como variável independente e “Energy Consumed (kWh)” como variável dependente.

Para as análises probabilísticas, foi adotada a hipótese indicada no enunciado de que a variável numérica selecionada segue uma Distribuição Normal. Os cálculos foram realizados com a biblioteca SciPy. A regressão foi desenvolvida com scikit-learn e o gráfico foi gerado com Matplotlib.

Objetivo

Este projeto tem como objetivo realizar uma análise estatística dos padrões de recarga de veículos elétricos, utilizando a linguagem de programação Python e a base de dados `ev_charging_patterns.csv`. A partir da variável “Energy Consumed (kWh)”, serão calculadas probabilidades considerando a hipótese de uma Distribuição Normal, incluindo a probabilidade de ocorrência de valores acima da mediana e a probabilidade de os valores estarem dentro do intervalo definido pela média $\pm$ dois desvios padrão. Além disso, será desenvolvido um modelo de Regressão Linear, utilizando a duração de recarga como variável independente e a energia consumida como variável dependente, buscando analisar a relação entre essas variáveis e interpretar o desempenho do modelo por meio do coeficiente de determinação (R^2).

Dessa forma, o trabalho busca aplicar conceitos de estatística na análise de dados reais, desenvolvendo uma compreensão prática sobre distribuição de probabilidades, medidas estatísticas, regressão linear e interpretação dos resultados obtidos por meio de ferramentas computacionais.

Base de Dados

A base de dados foi pega no site do Kaggle, possui 1320 registros, com 21 dados (colunas).

Variáveis

Variáveis Qualitativas Nominais

As variáveis qualitativas nominais utilizadas na base de dados foram:

- **ID do usuário**
- **Modelo do veículo**
- **ID da estação carregamento**
- **Localização da estação**
- **Tipo de carregador (Nível 1 / Nível 2 / Carregador rápido)**
- **Tipo de usuário (Viajante / Casual / Viajante de longa distância)**

Variáveis Qualitativas Ordinais:

As variáveis qualitativas ordinais utilizadas na base de dados foram:

- **Hora do dia**
- **Dia da semana**

Variáveis Quantitativas Discretas

As variáveis quantitativas discretas utilizadas na base de dados foram:

- **Idade do veículo (anos)**
- **Número de veículos cadastrados por usuário**

Variáveis Quantitativas Contínua

As variáveis quantitativas contínuas utilizadas na base de dados foram:

- **Capacidade da bateria (kWh)**
- **Horário de início de carregamento**
- **Horário de término de carregamento**
- **Energia consumida (kWh)**

- **Duração de carregamento (horas)**
- **Taxa de carregamento (kW)**
- **Custo de carregamento (USD)**
- **Estado de carga (início %)**
- **Estado de carga (fim %)**
- **Distância percorrida desde a última carga (km)**
- **Temperatura (°C)**

01) Probabilidade acima da Mediana

Cálculo da mediana

A mediana observada para Energy Consumed (kWh) foi de 42.6914 kWh. A média foi 42.6429 kWh e o desvio padrão amostral foi 22.4117

Cálculo da probabilidade

Considerando $X \sim N (\mu = 42.6429, \sigma = 22.4117)$, foi calculada a probabilidade de observar um consumo acima da mediana:

$$P(X > 42.6914) = 1 - \Phi((42.6914 - 42.6429) / 22.4117) = 0.499136, \text{ ou } 49.91$$

Classificação e interpretação

Segundo a regra de classificação implementada no código, probabilidades entre 40% e 90% são classificadas como prováveis. Portanto, o evento foi classificado como **provável**.

Em termos práticos, sob a hipótese de normalidade, existe aproximadamente 49.91% de probabilidade de uma observação apresentar consumo superior à mediana de 42.69 kWh. Como a mediana está muito próxima da média, o resultado fica próximo de 50%, o que é coerente com a simetria esperada de uma distribuição normal.

02) Probabilidade no intervalo Média $\pm$ 2s

Média, desvio padrão e intervalo

A média do consumo foi de 42.6429 kWh e o desvio padrão foi de 22.4117 kWh. O intervalo solicitado é $\mu \pm 2\sigma$:

$$\text{Limite inferior} = 42.6429 - 2(22.4117) = -2.1805 \text{ kWh}$$

$$\text{Limite superior} = 42.6429 + 2(22.4117) = 87.4663 \text{ kW}$$

Cálculo da probabilidade

A probabilidade calculada pela função de distribuição acumulada normal foi $P(-2.1805 < X < 87.4663) = 0.954500$, equivalente a 95.45%.

Classificação e interpretação

O evento foi classificado como quase certo, pois a probabilidade é superior a 90%. O resultado também está alinhado à conhecida regra empírica da Distribuição Normal, aproximadamente 95% das observações ficam dentro de dois desvios padrão da média.


03) Modelagem com Regressão Linear

Variáveis e modelo

O modelo utiliza Charging Duration (hours) como variável independente (X) e Energy Consumed (kWh) como variável dependente (y). O modelo ajustado pode ser escrito como:

$$\text{Energia Consumida} = 41.2833 + (0.5967 \times \text{Duração da Recarga})$$

Gráfico da reta ajustada



Interpretação dos coeficientes

Intercepto (41.2833): representa o valor estimado de energia consumida quando a duração da recarga é igual a zero hora. Embora seja necessário para definir a reta matematicamente, essa situação pode não ter interpretação física relevante no contexto de uma sessão real de recarga.

Coefficiente angular (0.5967): indica que, de acordo com o modelo, cada hora adicional de duração de recarga está associada a um aumento médio estimado de 0.5967 kWh no consumo de energia.

$R^2 = 0.000805$ (0,08%): o valor de R^2 é muito baixo. Isso significa que a duração da recarga, sozinha, explica apenas cerca de 0.08% da variabilidade observada no consumo de energia nessa base. Portanto, a relação linear simples encontrada possui baixo poder explicativo e preditivo.

Do ponto de vista de aprendizado de máquina, o resultado sugere que um modelo mais adequado deveria considerar outras características disponíveis na base, como capacidade da bateria, taxa de carregamento, estado de carga inicial e final, distancia percorrida e tipo de carregado. A inclusão dessas variáveis poderia melhorar a capacidade de explicação e previsão,

Conclusão

O trabalho em dividido em três etapas. Primeiro, a Distribuição Normal é utilizada para transformar medidas descritivas (média, mediana e desvio padrão) em probabilidades. Em seguida, o intervalo de dois desvios padrão mostra a concentração esperada dos dados sob a hipótese de normalidade. Por fim, a Regressão Linear busca modelar uma relação entre duração da recarga e energia consumida.

Os resultados mostram que a probabilidade acima da mediana é próxima de 50%, enquanto a probabilidade dentro de média $\pm 2s$ é de aproximadamente 95,45%. Na regressão, apesar de o coeficiente angular ser positivo, o R^2 extremamente baixo indica que a duração da recarga isoladamente não é suficiente para explicar o consumo de energia.

A análise atendeu aos três objetivos técnicos propostos: cálculo de probabilidades sob a hipótese de normalidade, cálculo do intervalo média $\pm 2s$ padrão e construção de um modelo de Regressão Linear em Python. Os resultados obtidos permitiram compreender a distribuição do consumo de energia e sua relação com a duração da recarga. Além disso, a análise da regressão mostrou que, considerando apenas a duração de recarga, a capacidade de explicar a variação no consumo de energia é bastante limitada.

Referências

<https://www.kaggle.com/datasets/valakhorasani/electric-vehicle-charging-patterns>